# 分布式搜索引擎03

# 0.学习目标

# 1.数据聚合

聚合 (aggregations) 可以让我们极其方便的实现对数据的统计、分析、运算。例如:

- 什么品牌的手机最受欢迎?
- 这些手机的平均价格、最高价格、最低价格?
- 这些手机每月的销售情况如何?

实现这些统计功能的比数据库的sq1要方便的多,而且查询速度非常快,可以实现近实时搜索效果。

# 1.1.聚合的种类

#### 聚合常见的有三类:

• 桶 (Bucket) 聚合: 用来对文档做分组

。 TermAggregation: 按照文档字段值分组, 例如按照品牌值分组、按照国家分组

。 Date Histogram: 按照日期阶梯分组, 例如一周为一组, 或者一月为一组

• **度量 (Metric)** 聚合:用以计算一些值,比如:最大值、最小值、平均值等

Avg: 求平均值Max: 求最大值Min: 求最小值

。 Stats: 同时求max、min、avg、sum等

• 管道 (pipeline) 聚合: 其它聚合的结果为基础做聚合

注意:参加聚合的字段必须是keyword、日期、数值、布尔类型

# 1.2.DSL实现聚合

现在,我们要统计所有数据中的酒店品牌有几种,其实就是按照品牌对数据分组。此时可以根据酒店品牌的名称做聚合,也就是Bucket聚合。

### 1.2.1.Bucket聚合语法

语法如下:

```
1 GET /hotel/_search
2 {
3    "size": 0, // 设置size为0, 结果中不包含文档, 只包含聚合结果
4    "aggs": { // 定义聚合
5    "brandAgg": { //给聚合起个名字
6    "terms": { // 聚合的类型, 按照品牌值聚合, 所以选择term
7    "field": "brand", // 参与聚合的字段
8    "size": 20 // 希望获取的聚合结果数量
9    }
10    }
11    }
12 }
```

结果如图:

```
"took" : 16,
"timed out" : false,
" shards" : {},
"hits" : { ),
"aggregations" : {
                    → 对品牌的聚合
 "brandAgg" . T
   "doc_count_error_upper_bound" : 0,
   "sum_other_doc_count" : 41,
   "buckets": [ 聚合的bucket数组
      "key" : "7天酒店",品牌为"7天酒店"的桶
     },
      "key" : "如家", 品牌为"如家"的桶
      "doc count" : 30
      "key" : "速8", 品牌为"速8"的桶
     "doc count" : 20
        (AVII . II 自 字 把 口 II
```

### 1.2.2.聚合结果排序

默认情况下,Bucket聚合会统计Bucket内的文档数量,记为 *count ,并且按照* count降序排序。 我们可以指定order属性,自定义聚合的排序方式:

# 1.2.3.限定聚合范围

默认情况下,Bucket聚合是对索引库的所有文档做聚合,但真实场景下,用户会输入搜索条件,因此聚合必须是对搜索结果聚合。那么聚合必须添加限定条件。

我们可以限定要聚合的文档范围,只要添加query条件即可:

这次,聚合得到的品牌明显变少了:

```
GET /hotel/_search
                                                   D 2
                                                                18 -
                                                                       "aggregations" : {
                                                                19 🕶
                                                                          "brandAgg" : {
  "query": {
                                                                 20
                                                                           "doc_count_error_upper_bound" : 0,
                                                                           "sum_other_doc_count" : 0,
"buckets" : [
    "range": {
                                                                 21
      "price": {
                                                                 22 +
                      只对200元以下的酒店聚合
     "lte": 200
                                                                 23 🕶
                                                                                "key" : "如家",
                                                                 24
                                                                 25
                                                                               "doc_count" : 13
                                                                                                         200元以下
                                                                 26 -
                                                                                                         的酒店只剩
  "size": 0,
                                                                 27 🕶
                                                                                                         下3个品牌
                                                            "key" : "速8",
  "aggs": {
                                                                 28
    "brandAgg": {
                                                                 29
                                                                               "doc_count" : 2
     "terms": {
| "field": "brand",
                                                                 30 -
                                                                 31 -
                                                                                "key": "汉庭",
       "size": 20
                                                                 32
                                                                               "doc_count" : 1
                                                                 33
    }
                                                                 34 -
                                                                 35 -
```

# 1.2.4.Metric聚合语法

上节课,我们对酒店按照品牌分组,形成了一个个桶。现在我们需要对桶内的酒店做运算,获取每个品牌的用户评分的min、max、avg等值。

这就要用到Metric聚合了,例如stat聚合:就可以获取min、max、avg等结果。

语法如下:

```
1 GET /hotel/_search
{
3     "size": 0,
4     "aggs": {
5         "brandAgg": {
6               "field": "brand",
8               "size": 20
9              },
10              "aggs": { // 是brands聚合的子聚合,也就是分组后对每组分别计算
11              "score_stats": { // 聚合名称
12               "stats": { // 聚合各和
12               "stats": { // 聚合各和
13               "field": "score" // 聚合字段,这里是score
14               }
15               }
16               }
17              }
18               }
19               }
```

这次的score\_stats聚合是在brandAgg的聚合内部嵌套的子聚合。因为我们需要在每个桶分别计算。

另外, 我们还可以给聚合结果做个排序, 例如按照每个桶的酒店平均分做排序:

```
}
                                                                                                                               "sum" : 370.0
                                                                                                    53
                                                                                                    54 ^
                                                                                                                        \}, <sup>'</sup>
                                                                                                    55 ^
                                                                                                    56 ₹
                                                                                                                           "key": "和顾",
                                                                                                    57
# 嵌套聚合metric
                                                                                                                           "doc_count" : 12,
GET /hotel/_search
                                                                                                                            "scoreAgg" : {
  "count" : 12,
                                                                                                    59 +
                                                                                                    60
   "size": 0,
                                                                                                                              "min" : 44.0,
"max" : 47.0,
                                                                                                    61
   "aggs": {
       "brandAgg": {
    "terms": {
                                                                                                    62
                                                                                                                              'avg" : 46.08333333333333336,
"sum" : 553.0
                                                                                                    63
                                                                                                    64
             "field": "brand",
                                                                                                    65 ^
            "size": 20,
"order": {
                                                                                                    66 -
                                                                                                    67 🕶
                "scoreAgg.avg": "desc"
                                                                                                                           "key": "喜来登",
                                                                                                    68
                                                                                                                          "key": "喜来登",
"doc_count": 14,
"scoreAgg": {
    "count": 14,
    "min": 44.0,
    "max": 48.0,
    "avg": 46.07142857142857,
    "sum": 645.0
                                                                                                    69
                                                                                                    70 -
           "aggs": {
             "scoreAgg": {
| "stats": {
| "field": "score"
                                                                                                    71
                                                                                                     72
                                                                                                    73
                                                                                                     74
                                                                                                     75
```

## 1.2.5.小结

aggs代表聚合,与query同级,此时query的作用是?

• 限定聚合的的文档范围

#### 聚合必须的三要素:

- 聚合名称
- 聚合类型
- 聚合字段

### 聚合可配置属性有:

• size: 指定聚合结果数量

• order: 指定聚合结果排序方式

• field: 指定聚合字段

# 1.3.RestAPI实现聚合

## 1.3.1.API语法

聚合条件与query条件同级别,因此需要使用request.source()来指定聚合条件。

聚合条件的语法:

```
GET /hotel/_search
                                                           {
request.source().size(0);
                                                             "size": 0,
request.source().aggregation(
                                                             "aggs": {
        AggregationBuilders
                                                               "brand_agg": {
                 .terms(<mark>"brand_agg"</mark>
                                                                  "terms": {
                 .field("brand")
                                                                    "field": "brand",
                 .size(20)
                                                                    "size": 20
);
                                                                  }
                                                             }
```

聚合的结果也与查询结果不同,API也比较特殊。不过同样是JSON逐层解析:

```
"took" : 1,
                                                                               "timed_out" : false,
                                                                               "_shards" : {...},
                                                                               "hits" : {...},

"aggregations" : {
    "brand_agg" : {
    "buckets" : [
// 解析聚合结果
Aggregations aggregations = response.getAggregations();
// 根据名称获取聚合结果
                                                                                       "key" : "如家",
Terms brandTerms = aggregations.get("brand_agg");
                                                                                       "doc_count" : 13
List<? extends Terms.Bucket> buckets = brandTerms.getBuckets();
                                                                                       "key" : "速8",
                                                                                       "doc_count" : 2
for (Terms.Bucket bucket : buckets) {
                                                                                       'key" : "汉庭",
     // 获取key, 也就是品牌信息
                                                                                       "doc_count" :
    String brandName = bucket.getKeyAsString();
     System.out.println(brandName);
}
```

## 1.3.2.业务需求

需求:搜索页面的品牌、城市等信息不应该是在页面写死,而是通过聚合索引库中的酒店数据得来的:



#### 分析:

目前,页面的城市列表、星级列表、品牌列表都是写死的,并不会随着搜索结果的变化而变化。但是用户搜索条件改变时,搜索结果会跟着变化。

例如:用户搜索"东方明珠",那搜索的酒店肯定是在上海东方明珠附近,因此,城市只能是上海,此时城市列表中就不应该显示北京、深圳、杭州这些信息了。

也就是说,搜索结果中包含哪些城市,页面就应该列出哪些城市;搜索结果中包含哪些品牌,页面就应该列出哪些品牌。

如何得知搜索结果中包含哪些品牌?如何得知搜索结果中包含哪些城市?

使用聚合功能,利用Bucket聚合,对搜索结果中的文档基于品牌分组、基于城市分组,就能得知包含哪些品牌、哪些城市了。

因为是对搜索结果聚合,因此聚合是**限定范围的聚合**,也就是说聚合的限定条件跟搜索文档的条件一致。

查看浏览器可以发现,前端其实已经发出了这样的一个请求:

```
▼ General

Request URL: http://localhost:8089/hotel/filters

Request Method: POST

Status Code: ● 404

Remote Address: [::1]:8089

Referrer Policy: strict-origin-when-cross-origin

▶ Response Headers (8)

▶ Request Headers (16)

▼ Request Payload view source

▼ {key: "外滩", page: 1, size: 5, sortBy: "default", minPrice: 300, maxPrice: 600}

key: "外滩"

maxPrice: 600

minPrice: 300

page: 1
```

#### 请求参数与搜索文档的参数完全一致。

返回值类型就是页面要展示的最终结果:



## 结果是一个Map结构:

- key是字符串,城市、星级、品牌、价格
- value是集合,例如多个城市的名称

## 1.3.3.业务实现

在 cn.itcast.hotel.web 包的 HotelController 中添加一个方法, 遵循下面的要求:

• 请求方式: POST

• 请求路径: /hotel/filters

• 请求参数: RequestParams , 与搜索文档的参数一致

• 返回值类型: Map<String, List<String>>

代码:

```
@PostMapping("filters")
public Map<String, List<String>> getFilters(@RequestBody RequestParams
params){
    return hotelService.getFilters(params);
}
```

这里调用了IHotelService中的getFilters方法,尚未实现。

在 cn.itcast.hotel.service.lHotelService 中定义新方法:

```
1 Map<String, List<String>> filters(RequestParams params);
```

在 cn.itcast.hotel.service.impl.HotelService 中实现该方法:

```
1 @Override
2 public Map<String, List<String>> filters(RequestParams params) {
           // 1.准备Request
           SearchRequest request = new SearchRequest("hotel");
           // 2.准备DSL
           // 2.1.query
           buildBasicQuery(params, request);
           // 2.2.设置size
           request.source().size(0);
           // 2.3.聚合
           buildAggregation(request);
           // 3.发出请求
           SearchResponse response = client.search(request,
   RequestOptions.DEFAULT);
           // 4.解析结果
           Map<String, List<String>> result = new HashMap<>();
           Aggregations aggregations = response.getAggregations();
```

```
// 4.1.根据品牌名称,获取品牌结果
           List<String> brandList = getAggByName(aggregations, "brandAgg");
           result.put("品牌", brandList);
20
           // 4.2.根据品牌名称,获取品牌结果
           List<String> cityList = getAggByName(aggregations, "cityAgg");
           result.put("城市", cityList);
           // 4.3.根据品牌名称,获取品牌结果
           List<String> starList = getAggByName(aggregations, "starAgg");
           result.put("星级", starList);
           return result;
       } catch (IOException e) {
           throw new RuntimeException(e);
   private void buildAggregation(SearchRequest request) {
       request.source().aggregation(AggregationBuilders
                                   .terms("brandAgg")
                                   .field("brand")
                                   .size(100)
       request.source().aggregation(AggregationBuilders
                                   .terms("cityAgg")
                                   .field("city")
                                   .size(100)
       request.source().aggregation(AggregationBuilders
                                   .terms("starAgg")
                                   .field("starName")
                                   .size(100)
   private List<String> getAggByName(Aggregations aggregations, String
   aggName) {
       // 4.1.根据聚合名称获取聚合结果
       Terms brandTerms = aggregations.get(aggName);
       // 4.2.获取buckets
       List<? extends Terms.Bucket> buckets = brandTerms.getBuckets();
       // 4.3.遍历
       List<String> brandList = new ArrayList<>();
       for (Terms.Bucket bucket : buckets) {
           // 4.4.获取key
           String key = bucket.getKeyAsString();
           brandList.add(key);
       return brandList;
```

# 2.自动补全

当用户在搜索框输入字符时,我们应该提示出与该字符有关的搜索项,如图:



这种根据用户输入的字母,提示完整词条的功能,就是自动补全了。

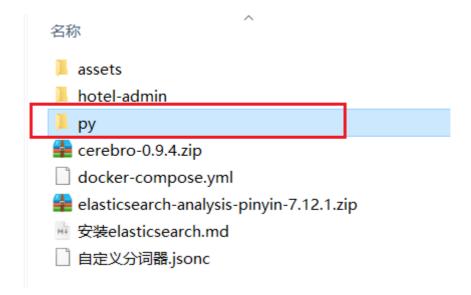
因为需要根据拼音字母来推断, 因此要用到拼音分词功能。

# 2.1.拼音分词器

要实现根据字母做补全,就必须对文档按照拼音分词。在GitHub上恰好有elasticsearch的拼音分词 插件。地址: <a href="https://github.com/medcl/elasticsearch-analysis-pinyin">https://github.com/medcl/elasticsearch-analysis-pinyin</a>



课前资料中也提供了拼音分词器的安装包:



## 安装方式与IK分词器一样,分三步:

⑩解压

②上传到虚拟机中, elasticsearch的plugin目录

③重启elasticsearch

④测试

详细安装步骤可以参考IK分词器的安装过程。

## 测试用法如下:

```
1 POST /_analyze
2 {
3 "text": "如家酒店还不错",
4 "analyzer": "pinyin"
5 }
```

结果:

```
"tokens" : [
  {
    "token"
    "start_offset" : 0,
    "end offset" : 0,
    "type" : "word",
    "position"
  },
    "token" : "Tiidhbc"
    "start offset" : 0,
    "end offset" : 0,
    "type" : "word",
    "position" : 0
  },
    "token" :
    "start_offset" :
    "end offset"
    "type" : "word",
    "position": 1
```

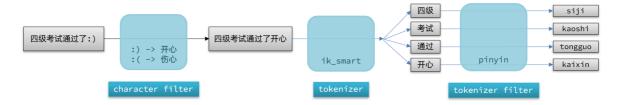
# 2.2.自定义分词器

默认的拼音分词器会将每个汉字单独分为拼音,而我们希望的是每个词条形成一组拼音,需要对拼音分词器做个性化定制,形成自定义分词器。

elasticsearch中分词器 (analyzer) 的组成包含三部分:

- character filters: 在tokenizer之前对文本进行处理。例如删除字符、替换字符
- tokenizer: 将文本按照一定的规则切割成词条 (term) 。例如keyword,就是不分词;还有ik\_smart
- tokenizer filter: 将tokenizer输出的词条做进一步处理。例如大小写转换、同义词处理、拼音处理等

文档分词时会依次由这三部分来处理文档:



### 声明自定义分词器的语法如下:

```
1 PUT /test
       "analyzer": { // 自定义分词器
         "my_analyzer": { // 分词器名称
       "filter": { // 自定义tokenizer filter
11
         "py": { // 过滤器名称
12
           "type": "pinyin", // 过滤器类型,这里是pinyin
```

#### 测试:

```
"tokens" : [
                                                                                  3 +
                                                                                            "token": "如家",
                                                                                  4
                                                                                            "start_offset" : 0,
"end_offset" : 2,
                                                                                  6
POST /test/_analyze
                                                                                            "type" : "CN_WORD",
                                                                                  7
                                                                                            "position" : 0
  "text": ["如家酒店还不错"],
"analyzer": "my_analyzer"
                                                                                  8
                                                                                  9 🛎
                                                                                 10 -
                                                                                            "token" : "rujia",
                                                                              11
                                                                                             "start_offset" : 0,
                                                                                 12
                                                                                             "end_offset" : 2,
                                                                                 13
                                                                                            "type" : "CN_WORD",
                                                                                 14
                                                                                            "position" : 0
                                                                                 15
                                                                                 16 -
                                                                                 17 *
                                                                                            "token" : "rj",
"start_offset" : 0,
                                                                                 18
                                                                                 19
                                                                                             "end offset" : 2,
                                                                                 20
                                                                                            "type" : "CN_WORD",
                                                                                 21
                                                                                            "position" : 0
                                                                                 22
                                                                                 23 *
                                                                                 24 🕶
                                                                                             "token" : "酒店",
                                                                                 25
                                                                                            "start_offset" : 2,
                                                                                 26
                                                                                            "end_offset" : 4,
                                                                                 27
```

#### 总结:

#### 如何使用拼音分词器?

- ①下载pinyin分词器
- ②解压并放到elasticsearch的plugin目录
- ③重启即可

#### 如何自定义分词器?

- ①创建索引库时,在settings中配置,可以包含三部分
- @character filter
- 3tokenizer
- @filter

#### 拼音分词器注意事项?

• 为了避免搜索到同音字,搜索时不要使用拼音分词器

# 2.3.自动补全查询

elasticsearch提供了<u>Completion Suggester</u>查询来实现自动补全功能。这个查询会匹配以用户输入内容开头的词条并返回。为了提高补全查询的效率,对于文档中字段的类型有一些约束:

- 参与补全查询的字段必须是completion类型。
- 字段的内容一般是用来补全的多个词条形成的数组。

比如,一个这样的索引库:

```
1  // 创建索引库
2  PUT test
3  {
4    "mappings": {
5         "properties": {
6          "title": {
7               "type": "completion"
8           }
9      }
10     }
11 }
```

然后插入下面的数据:

```
1  // 示例数据
2  POST test/_doc
3  {
4    "title": ["Sony", "WH-1000XM3"]
5  }
6  POST test/_doc
7  {
8    "title": ["SK-II", "PITERA"]
9  }
10  POST test/_doc
11  {
12    "title": ["Nintendo", "switch"]
13  }
```

#### 查询的DSL语句如下:

```
1 // 自动补全查询
2 GET /test/_search
3 {
4    "suggest": {
5     "title_suggest": {
6         "text": "s", // 关键字
7         "completion": {
8             "field": "title", // 补全查询的字段
9             "skip_duplicates": true, // 跳过重复的
10             "size": 10 // 获取前10条结果
11             }
12             }
13             }
14             }
```

# 2.4.实现酒店搜索框自动补全

现在,我们的hote1索引库还没有设置拼音分词器,需要修改索引库中的配置。但是我们知道索引库是无法修改的,只能删除然后重新创建。

另外,我们需要添加一个字段,用来做自动补全,将brand、suggestion、city等都放进去,作为自动补全的提示。

因此, 总结一下, 我们需要做的事情包括:

- 1. 修改hotel索引库结构,设置自定义拼音分词器
- 2. 修改索引库的name、all字段,使用自定义分词器
- 3. 索引库添加一个新字段suggestion, 类型为completion类型, 使用自定义的分词器
- 4. 给HotelDoc类添加suggestion字段,内容包含brand、business
- 5. 重新导入数据到hotel库

## 2.4.1.修改酒店映射结构

代码如下:

## 2.4.2.修改HotelDoc实体

HotelDoc中要添加一个字段,用来做自动补全,内容可以是酒店品牌、城市、商圈等信息。按照自动补全字段的要求,最好是这些字段的数组。

因此我们在HotelDoc中添加一个suggestion字段,类型为 List < String > ,然后将brand、city、business等信息放到里面。

代码如下:

```
package cn.itcast.hotel.pojo;
3 import lombok.Data;
4 import lombok.NoArgsConstructor;
6 import java.util.ArrayList;
   import java.util.Arrays;
8 import java.util.Collections;
9 import java.util.List;
11 @Data
12 @NoArgsConstructor
13
   public class HotelDoc {
       private Long id;
       private String name;
       private String address;
       private Integer price;
       private Integer score;
       private String brand;
       private String city;
       private String starName;
       private String business;
       private String location;
       private String pic;
       private Object distance;
       private Boolean isAD;
       private List<String> suggestion;
       public HotelDoc(Hotel hotel) {
            this.id = hotel.getId();
            this.name = hotel.getName();
            this.address = hotel.getAddress();
           this.price = hotel.getPrice();
```

```
this.score = hotel.getScore();
       this.brand = hotel.getBrand();
       this.city = hotel.getCity();
       this.starName = hotel.getStarName();
       this.business = hotel.getBusiness();
       this.location = hotel.getLatitude() + ", " +
hotel.getLongitude();
       this.pic = hotel.getPic();
       // 组装suggestion
       if(this.business.contains("/")){
           // business有多个值,需要切割
           String[] arr = this.business.split("/");
           // 添加元素
           this.suggestion = new ArrayList<>();
           this.suggestion.add(this.brand);
           Collections.addAll(this.suggestion, arr);
           this.suggestion = Arrays.asList(this.brand, this.business);
```

## 2.4.3.重新导入

重新执行之前编写的导入数据功能,可以看到新的酒店数据中包含了suggestion:

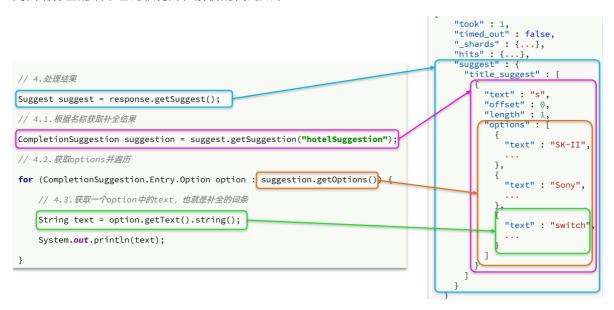
```
"business": "江湾/五角场商业区",
    "city": "上海",
    "id": 39141,
    "location": "31.290057, 121.508804",
    "name": "7天连锁酒店(上海五角场复旦同济大学店)",
    "pic": "https://m.tuniucdn.com/fb2/t1/G2/M00/C7/E3/Cii-T1knFX
    -uFNAEAKYkQPcw1IAAUIL012_w200_h200_c1_t0.jpg",
    "price": 349,
    "score": 38,
    "starName": "二钴",
    "suggestion": [
    "7天酒店",
    "江湾",
    "五角场商业区"
```

# 2.4.4. 自动补全查询的JavaAPI

之前我们学习了自动补全查询的DSL,而没有学习对应的JavaAPI,这里给出一个示例:

```
// 自动补全查询
// 1.准备请求
                                                                GET /test/_search
SearchRequest request = new SearchRequest("hotel");
                                                                {
// 2.请求参数
                                                                  "suggest": {
request.source()
                                                                    "mySuggestion": {
       .suggest(new SuggestBuilder().addSuggestion(
                                                                      "text": "h", // 关键字
              "mySuggestion",
               SuggestBuilders
                                                                       'completion": {
                                                                        "field": "title", // 补全字段
                      .completionSuggestion("title")
                      .prefix("h")
                                                                        "skip_duplicates": true,
                      .skipDuplicates(true)
                                                                        "size": 10 // 获取前10条结果
                       .size(10)
       ));
                                                                    }
// 3.发送请求
                                                                  }
client.search(request, RequestOptions.DEFAULT);
```

而自动补全的结果也比较特殊,解析的代码如下:



## 2.4.5.实现搜索框自动补全

查看前端页面,可以发现当我们在输入框键入时,前端会发起ajax请求:

```
▼ General

Request URL: http://localhost:8089/hotel/suggestion?key=h
Request Method: GET
Status Code: ● 404
Remote Address: [::1]:8089
Referrer Policy: strict-origin-when-cross-origin

▶ Response Headers (8)
▶ Request Headers (13)
▼ Query String Parameters view source view URL-encoded
key: h
```

1) 在 cn.itcast.hotel.web 包下的 HotelController 中添加新接口,接收新的请求:

```
@GetMapping("suggestion")
public List<String> getSuggestions(@RequestParam("key") String prefix) {
    return hotelService.getSuggestions(prefix);
}
```

2) 在 cn.itcast.hotel.service 包下的 lhotelService 中添加方法:

```
1 List<String> getSuggestions(String prefix);
```

3) 在 cn.itcast.hotel.service.impl.HotelService 中实现该方法:

```
1 @Override
2 public List<String> getSuggestions(String prefix) {
           // 1.准备Request
           SearchRequest request = new SearchRequest("hotel");
           // 2.准备DSL
           request.source().suggest(new SuggestBuilder().addSuggestion(
               SuggestBuilders.completionSuggestion("suggestion")
               .prefix(prefix)
10
               .skipDuplicates(true)
11
               .size(10)
12
           ));
13
           // 3.发起请求
           SearchResponse response = client.search(request,
   RequestOptions.DEFAULT);
          // 4.解析结果
           Suggest suggest = response.getSuggest();
           // 4.1.根据补全查询名称, 获取补全结果
           CompletionSuggestion suggestions =
   suggest.getSuggestion("suggestions");
           // 4.2.获取options
           List<CompletionSuggestion.Entry.Option> options =
21
   suggestions.getOptions();
           // 4.3.遍历
           List<String> list = new ArrayList<>(options.size());
           for (CompletionSuggestion.Entry.Option option : options) {
               String text = option.getText().toString();
               list.add(text);
```

```
27  }
28    return list;
29  } catch (IOException e) {
30    throw new RuntimeException(e);
31  }
32 }
```

# 3.数据同步

elasticsearch中的酒店数据来自于mysql数据库,因此mysql数据发生改变时,elasticsearch也必须跟着改变,这个就是elasticsearch与mysql之间的**数据同步**。



在微服务中,负责酒店管理(操作mysql )的业务与负责酒店搜索(操作elasticsearch )的业务可能在两个<mark>不同</mark>的微服务上,数据同步该如何实现呢?

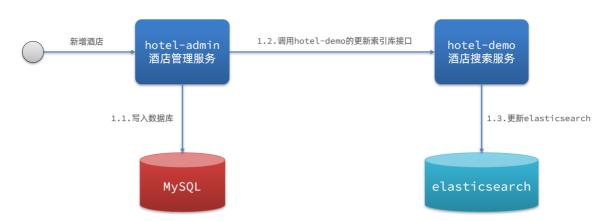
# 3.1.思路分析

常见的数据同步方案有三种:

- 同步调用
- 异步通知
- 监听binlog

# 3.1.1.同步调用

方案一: 同步调用

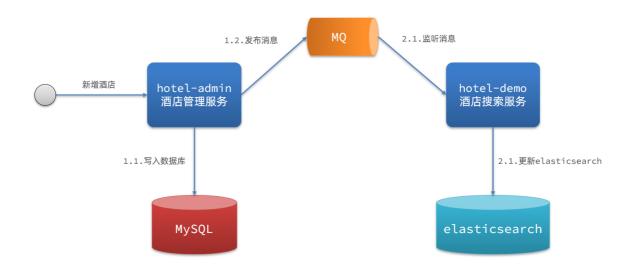


#### 基本步骤如下:

- hotel-demo对外提供接口,用来修改elasticsearch中的数据
- 酒店管理服务在完成数据库操作后,直接调用hotel-demo提供的接口,

# 3.1.2.异步通知

方案二: 异步通知

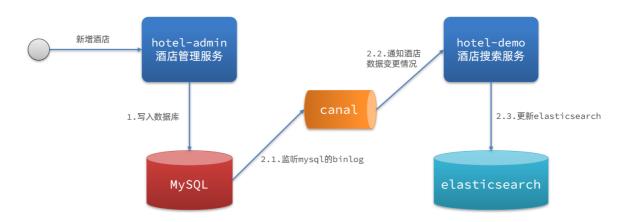


#### 流程如下:

- hotel-admin对mysql数据库数据完成增、删、改后,发送MQ消息
- hotel-demo监听MQ,接收到消息后完成elasticsearch数据修改

## 3.1.3. 监听binlog

方案三: 监听binlog



### 流程如下:

- 给mysql开启binlog功能
- mysql完成增、删、改操作都会记录在binlog中
- hotel-demo基于canal监听binlog变化,实时更新elasticsearch中的内容

## 3.1.4.选择

方式一: 同步调用

• 优点:实现简单,粗暴 • 缺点:业务耦合度高

方式二: 异步通知

• 优点: 低耦合, 实现难度一般 • 缺点: 依赖mq的可靠性

方式三: 监听binlog

• 优点: 完全解除服务间耦合

• 缺点: 开启binlog增加数据库负担、实现复杂度高

# 3.2.实现数据同步

## 3.2.1.思路

利用课前资料提供的hotel-admin项目作为酒店管理的微服务。当酒店数据发生增、删、改时,要求对elasticsearch中数据也要完成相同操作。

#### 步骤:

- 导入课前资料提供的hotel-admin项目, 启动并测试酒店数据的CRUD
- 声明exchange、queue、RoutingKey
- 在hotel-admin中的增、删、改业务中完成消息发送
- 在hotel-demo中完成消息监听,并更新elasticsearch中数据
- 启动并测试数据同步功能

## 3.2.2.导入demo

导入课前资料提供的hotel-admin项目:

assets	文件夹	
hotel-admin	文件夹	
py py	文件夹	
Lerebro-0.9.4.zip 好压 ZIP 压缩文件		
docker-compose.yml	YML文件	
🛖 elasticsearch-analysis-pinyin-7.12.1.zip	好压 ZIP 压缩文件	
₩ 安装elasticsearch.md	Markdown File	
自定义分词器.jsonc	JSONC 文件	

运行后,访问 http://localhost:8099

## 酒店数据管理

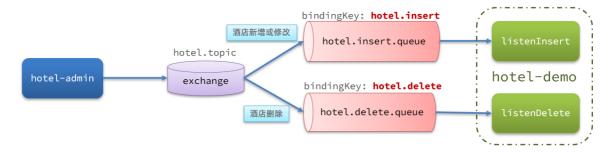
新增酒店					
ID	酒店名称	酒店品牌	酒店价格	所在商圈	操作
36934	7天连锁酒店(上海宝山路地铁站店)	7天酒店	338	四川北路商业区	2
38609	速8酒店(上海赤峰路店)	速8	247	四川北路商业区	2 1
38665	速8酒店上海中山北路兰田路店	速8	216	长风公园	2 1
38812	7天连锁酒店(上海漕溪路地铁站店)	7天酒店	298	八万人体育场	2 1
39106	7天连锁酒店 (上海莘庄地铁站店)	7天酒店	348	莘庄工业区	2 1
( 1 2 3 4 5 6 46 >					

### 其中包含了酒店的CRUD功能:

```
notel-admin) ×
          © HotelController.java ×
                             🦽 application.yaml × 🕒 MqConstants.java ×
   @PostMapping
   public void saveHotel(@RequestBody Hotel hotel){
        hotelService.save(hotel);
   }
   @PutMapping()
   public void updateById(@RequestBody Hotel hotel){
        if (hotel.getId() == null) {
            throw new InvalidParameterException("id不能为空");
        hotelService.updateById(hotel);
   }
   @DeleteMapping("/{id}")
   public void deleteById(@PathVariable("id") Long id) {
        hotelService.removeById(id);
```

## 3.2.3.声明交换机、队列

MQ结构如图:



# 1) 引入依赖

在hotel-admin、hotel-demo中引入rabbitmq的依赖:

# 2) 声明队列交换机名称

在hotel-admin和hotel-demo中的 cn.itcast.hotel.constatnts 包下新建一个类 MqConstants:

```
public class MqConstants;

public class MqConstants {
    /**
    * 交换机
    */
public final static String HOTEL_EXCHANGE = "hotel.topic";
    /**
    * 监听新增和修改的队列
    */
public final static String HOTEL_INSERT_QUEUE = "hotel.insert.queue";
    /**
    * 监听删除的队列
    */
    public final static String HOTEL_DELETE_QUEUE = "hotel.delete.queue";
    /**
    * 监听删除的队列
    */
    public final static String HOTEL_DELETE_QUEUE = "hotel.delete.queue";
    /**
    * 新增或修改的RoutingKey
    */
```

```
public final static String HOTEL_INSERT_KEY = "hotel.insert";

/**

* 删除的RoutingKey

*/

public final static String HOTEL_DELETE_KEY = "hotel.delete";

}
```

# 3) 声明队列交换机

在hotel-demo中, 定义配置类, 声明队列、交换机:

```
• • •
package cn.itcast.hotel.config;
3 import cn.itcast.hotel.constants.MgConstants;
4 import org.springframework.amqp.core.Binding;
5 import org.springframework.amqp.core.BindingBuilder;
6 import org.springframework.amqp.core.Queue;
   import org.springframework.amqp.core.TopicExchange;
8 import org.springframework.context.annotation.Bean;
   import org.springframework.context.annotation.Configuration;
11 @Configuration
12  public class MqConfig {
       @Bean
       public TopicExchange topicExchange(){
14
           return new TopicExchange(MqConstants.HOTEL_EXCHANGE, true,
       @Bean
       public Queue insertQueue(){
            return new Queue(MqConstants.HOTEL_INSERT_QUEUE, true);
       @Bean
       public Queue deleteQueue(){
           return new Queue(MqConstants.HOTEL_DELETE_QUEUE, true);
       @Bean
        public Binding insertQueueBinding(){
    BindingBuilder.bind(insertQueue()).to(topicExchange()).with(MqConstants.H
    OTEL_INSERT_KEY);
       @Bean
       public Binding deleteQueueBinding(){
```

```
35          return
          BindingBuilder.bind(deleteQueue()).to(topicExchange()).with(MqConstants.H
          OTEL_DELETE_KEY);
36      }
37 }
```

## 3.2.4.发送MQ消息

在hotel-admin中的增、删、改业务中分别发送MQ消息:

```
| MyConstants, available | MyConstants, avail
```

## 3.2.5.接收MQ消息

hotel-demo接收到MQ消息要做的事情包括:

- 新增消息:根据传递的hotel的id查询hotel信息,然后新增一条数据到索引库
- 删除消息:根据传递的hotel的id删除索引库中的一条数据
- 1) 首先在hotel-demo的 cn.itcast.hotel.service 包下的 IHotelService 中新增新增、删除业务

```
void deleteById(Long id);

void insertById(Long id);
```

2) 给hotel-demo中的 cn.itcast.hotel.service.impl 包下的HotelService中实现业务:

```
1 @Override
2 public void deleteById(Long id) {
```

```
// 1.准备Request
           DeleteRequest request = new DeleteRequest("hotel",
   id.toString());
           // 2.发送请求
           client.delete(request, RequestOptions.DEFAULT);
       } catch (IOException e) {
           throw new RuntimeException(e);
11
12
   @Override
   public void insertById(Long id) {
           // 0.根据id查询酒店数据
           Hotel hotel = getById(id);
           // 转换为文档类型
           HotelDoc hotelDoc = new HotelDoc(hotel);
           // 1.准备Request对象
21
           IndexRequest request = new
   IndexRequest("hotel").id(hotel.getId().toString());
           // 2.准备Json文档
           request.source(JSON.toJSONString(hotelDoc), XContentType.JSON);
           // 3.发送请求
           client.index(request, RequestOptions.DEFAULT);
       } catch (IOException e) {
           throw new RuntimeException(e);
```

#### 3)编写监听器

在hotel-demo中的 cn.itcast.hotel.mg 包新增一个类:

```
package cn.itcast.hotel.mq;

import cn.itcast.hotel.constants.MqConstants;

import cn.itcast.hotel.service.IHotelService;

import org.springframework.amqp.rabbit.annotation.RabbitListener;

import org.springframework.beans.factory.annotation.Autowired;

import org.springframework.stereotype.Component;

@Component

public class HotelListener {

@Autowired

private IHotelService hotelService;
```

```
## 16 * 监听酒店新增或修改的业务

## 2 * @param id 酒店id

## 2 * @RabbitListener(queues = MqConstants.HOTEL_INSERT_QUEUE)

## 20 public void listenHotelInsertOrUpdate(Long id) {

## 21 hotelService.insertById(id);

## 22 }

## 25 * 监听酒店删除的业务

## 26 * @param id 酒店id

## 27 */

## 28 @RabbitListener(queues = MqConstants.HOTEL_DELETE_QUEUE)

## 29 public void listenHotelDelete(Long id) {

## 20 hotelService.deleteById(id);

## 31 }

## 32 }
```

# 4.集群

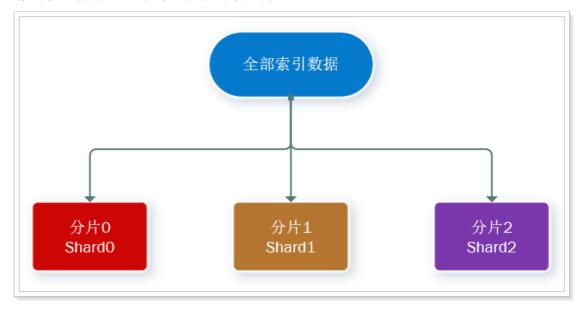
单机的elasticsearch做数据存储,必然面临两个问题:海量数据存储问题、单点故障问题。

- 海量数据存储问题:将索引库从逻辑上拆分为N个分片(shard),存储到多个节点
- 单点故障问题:将分片数据在不同节点备份 (replica )

#### ES集群相关概念:

- 集群 (cluster): 一组拥有共同的 cluster name 的 节点。
- 节点 (node) : 集群中的一个 Elasticearch 实例
- <mark>分片(shard)</mark>: 索引可以被拆分为不同的部分进行存储,称为分片。在集群环境下,一个索引的不同分片可以拆分到不同的节点中

解决问题:数据量太大,单点存储量有限的问题。



此处,我们把数据分成3片: shard0、shard1、shard2

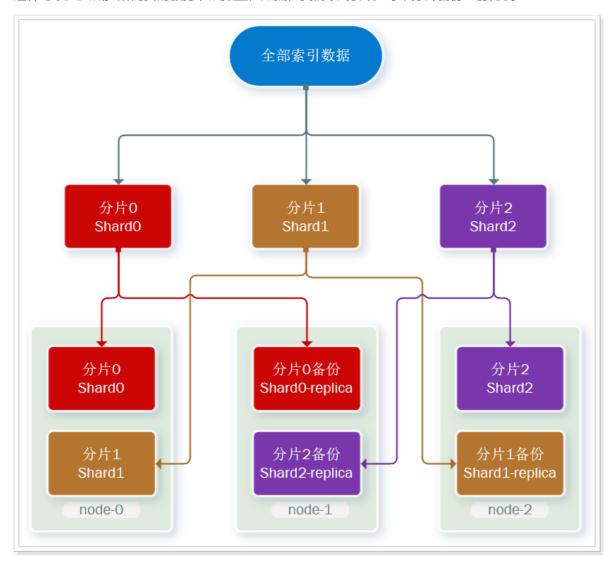
- 主分片 (Primary shard) : 相对于副本分片的定义。
- 副本分片 (Replica shard) 每个主分片可以有一个或者多个副本,数据和主分片一样。

数据备份可以保证高可用,但是每个分片备份一份,所需要的节点数量就会翻一倍,成本实在是太高了!

为了在高可用和成本间寻求平衡,我们可以这样做:

- 首先对数据分片,存储到不同节点
- 然后对每个分片进行备份,放到对方节点,完成互相备份

这样可以大大减少所需要的服务节点数量,如图,我们以3分片,每个分片备份一份为例:



#### 现在,每个分片都有1个备份,存储在3个节点:

node0:保存了分片0和1node1:保存了分片0和2node2:保存了分片1和2

#### 参考课前资料的文档:

名称	类型
assets	文件夹
hotel-admin	文件夹
py py	文件夹
de cerebro-0.9.4.zip	好压 ZIP 压缩文件
docker-compose.yml	YML文件
elasticsearch-analysis-pinyin-7.12.1.zip	好压 ZIP 压缩文件
🔟 安装elasticsearch.md	Markdown File
自定义分词器.jsonc	JSONC 文件

## 其中的第四章节:

安装elasticsearch

- > 1.部署单点es
- > 2.部署kibana
- > 3.安装IK分词器

# ~ 4.部署es集群

- 4.1.创建es集群
- 4.2.集群状态监控
- > 4.3.创建索引库
  - 4.4.查看分片效果

# 4.2.集群脑裂问题

# 4.2.1.集群职责划分

elasticsearch中集群节点有不同的职责划分:

节点类型	配置参数	默认值	节点职责
master eligible	node.master	true	备选主节点:主节点可以管理和记录集群状态、决定分片在哪个节点、处理创建和删除索引库的请求
data	node.data	true	数据节点:存储数据、搜索、聚合、CRUD
ingest	node.ingest	true	数据存储之前的预处理
coordinating	上面3个参数都为false 则为coordinating节点	无	路由请求到其它节点 合并其它节点处理的结果,返回给用户

默认情况下,集群中的任何一个节点都同时具备上述四种角色。

### 但是真实的集群一定要将集群职责分离:

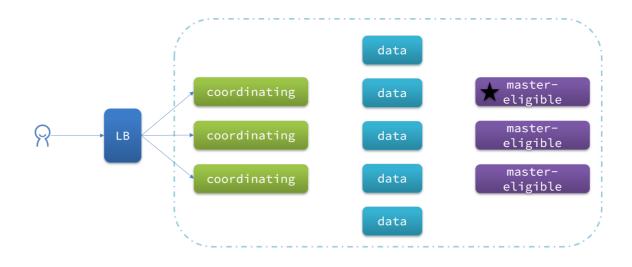
• master节点:对CPU要求高,但是内存要求第

• data节点:对CPU和内存要求都高

• coordinating节点: 对网络带宽、CPU要求高

职责分离可以让我们根据不同节点的需求分配不同的硬件去部署。而且避免业务之间的互相干扰。

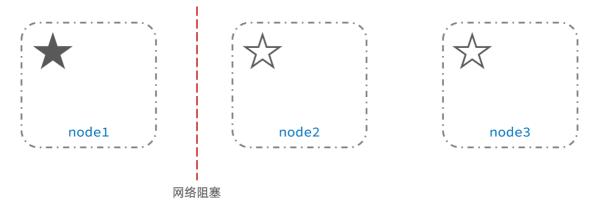
### 一个典型的es集群职责划分如图:



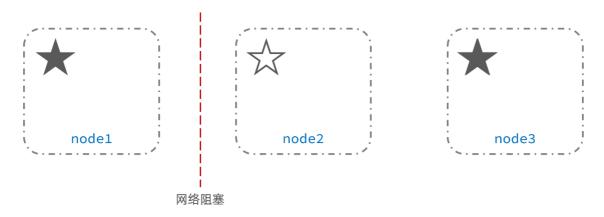
## 4.2.2.脑裂问题

脑裂是因为集群中的节点失联导致的。

例如一个集群中, 主节点与其它节点失联:



此时, node2和node3认为node1宕机, 就会重新选主:



当node3当选后,集群继续对外提供服务,node2和node3自成集群,node1自成集群,两个集群数据不同步,出现数据差异。

当网络恢复后,因为集群中有两个master节点,集群状态的不一致,出现脑裂的情况:



解决脑裂的方案是,要求选票超过( eligible节点数量 + 1 ) / 2 才能当选为主,因此eligible节点数量最好是奇数。对应配置项是discovery.zen.minimum\_master\_nodes,在es7.0以后,已经成为默认配置,因此一般不会发生脑裂问题

例如: 3个节点形成的集群,选票必须超过 (3 + 1) / 2 ,也就是2票。node3得到node2和node3的选票,当选为主。node1只有自己1票,没有当选。集群中依然只有1个主节点,没有出现脑裂。

# 4.2.3.小结

master eligible节点的作用是什么?

- 参与集群选主
- 主节点可以管理集群状态、管理分片信息、处理创建和删除索引库的请求

data节点的作用是什么?

• 数据的CRUD

coordinator节点的作用是什么?

- 路由请求到其它节点
- 合并查询到的结果,返回给用户

# 4.3.集群分布式存储

当新增文档时,应该保存到不同分片,保证数据均衡,那么coordinating node如何确定数据该存储到哪个分片呢?

# 4.3.1.分片存储测试

#### 插入三条数据:





## 测试可以看到,三条数据分别在不同分片:



结果:

```
" shard": "[itcast][1]",
  " node": "HhY3NGsLRii5CclmypsXJQ",
 " index": "itcast",
 "_type": "_doc",
 " id": "3",
 "_score": 1.0,
 " source": {
   "title": "试着插入一条 id = 3"
 },
 " explanation": {
   "value": 1.0,
   "description": "*:*",
   "details": []
 }
},
 "_shard": "[itcast][2]",
  " node": "APLhlP8qSoKs5gh9pmnC A",
 " index": "itcast",
 "_type": "_doc",
 "_id": "1",
 " score": 1.0,
 " source": {
    "title": "试着插入一条 id = 1"
```

# 4.3.2.分片存储原理

elasticsearch会通过hash算法来计算文档应该存储到哪个分片:

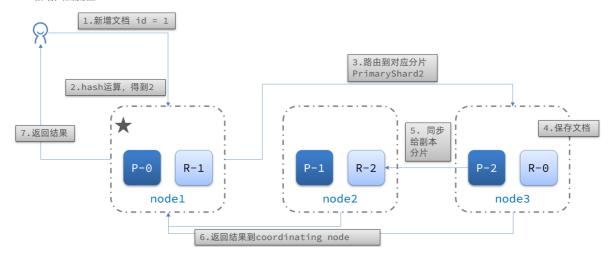
```
shard = hash(_routing) % number_of_shards
```

#### 说明:

- \_routing默认是文档的id
- 算法与分片数量有关,因此索引库一旦创建,分片数量不能修改!

#### 新增文档的流程如下:

#### 新增文档流程:



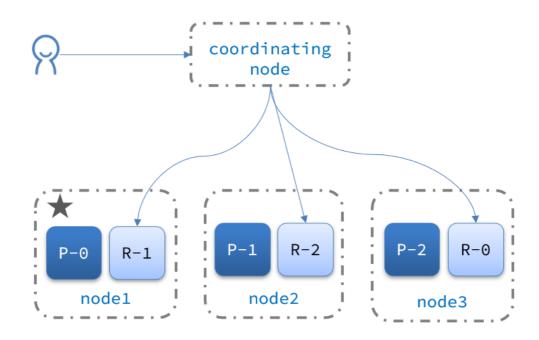
#### 解读:

- 1) 新增一个id=1的文档
- 2) 对id做hash运算,假如得到的是2,则应该存储到shard-2
- 3) shard-2的主分片在node3节点,将数据路由到node3
- 4) 保存文档
- 5) 同步给shard-2的副本replica-2, 在node2节点
- 6) 返回结果给coordinating-node节点

# 4.4.集群分布式查询

elasticsearch的查询分成两个阶段:

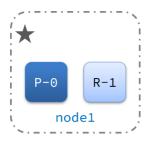
- scatter phase: 分散阶段, coordinating node会把请求分发到每一个分片
- gather phase: 聚集阶段, coordinating node汇总data node的搜索结果,并处理为最终结果 集返回给用户

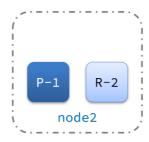


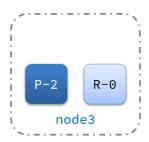
# 4.5.集群故障转移

集群的master节点会监控集群中的节点状态,如果发现有节点宕机,会立即将宕机节点的分片数据迁移 到其它节点,确保数据安全,这个叫做故障转移。

### 1) 例如一个集群结构如图:

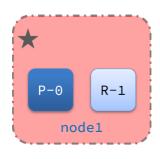


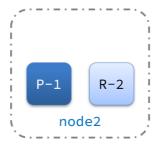


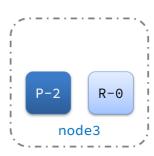


现在, node1是主节点, 其它两个节点是从节点。

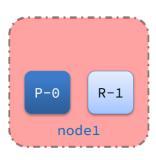
### 2) 突然, node1发生了故障:

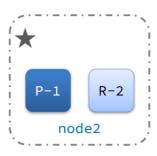


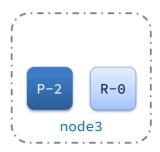




宕机后的第一件事,需要重新选主,例如选中了node2:







node2成为主节点后,会检测集群监控状态,发现: shard-1、shard-0没有副本节点。因此需要将 node1上的数据迁移到node2、node3:

